TP table de données, requêtes et tri

Traitement de données en tables

Première NSI Lycée du Parc

Table des matières

Crédits		1
1	Requêtes dans une table de données	1
2	Requêtes de recherche	2
3	Requêtes avec opération d'agrégation	3
4	Requêtes avec sélection de lignes	5
5	Requêtes avec projection sur des colonnes	6
6	Tri d'une table de données	8
7	Applications à un autre exemple	12
8	Synthèse	15

Crédits

Ce TP est largement inspiré :

- des chapitres 16 et 17 du manuel NSI de la collection Tortue chez Ellipse, auteurs : Ballabonski, Conchon, Filliatre, N'Guyen ;
- du document d'accompagnement des programmes de NSI disponible sur Eduscol

1 Requêtes dans une table de données



Définition 1

Dans le cours, on a vu comment charger une **table de données**, enregistrée dans un **fichier CSV**, dans une structure de données permettant un accès efficace aux **enregistrements** et aux valeurs de leurs **attributs**. En Python, une structure de données bien adaptée est un **tableau de dictionnaires**.

Les opérations sur les tableaux et les dictionnaires déjà étudiées vont nous permettre d'interroger une table de données à l'aide d'opération appelées requêtes :

- pour tester l'appartenance à la table d'un enregistrement vérifiant une certaine condition sur ses attributs;
- pour calculer une valeur en combinant les valeurs d'attributs de plusieurs enregistrements (opération d'agrégation);
- pour sélectionner tous les enregistrements vérifiant une certaine condition sur leurs attributs (opération de sélection par lignes);
- pour projeter les enregistrements sur certains de leurs attributs (opération de projection sur des colonnes);
- pour trier les enregistrements en fontion d'un ordre prédéfini sur leurs attributs (opération de

2 Requêtes de recherche



Exercice 1

- 1. Ouvrir le script 'TP_Recherche_Tris_Eleve.py' dans un IDE Python
- 2. Charger dans une variable table_clients la table contenue dans le fichier 'clients.csv ' à l'aide de la fonction lecture_csv qui est fournie. Il s'agit de la table des clients d'un site marchand que nous avons manipulée dans le cours. Exécuter le test unitaire test_import_table_clients(table_clients).

```
table_clients = lecture_csv('clients.csv', ',')
```

3. Compléter la fonction recherche attribut ci-dessous en respectant sa spécification. Vérifier en exécutant le test unitaire test_recherche_attribut_table_clients(table_clients).

```
def recherche_attribut(table, attribut, valeur):
   """Paramètres :
      table un tableau de dictionnaires, table de clients.csv
      attribut de type str valeur du type d'attribut dans table
   Valeur renvoyée:
      Un booléen indiquant si table contient un enregistrement e
      tel que e[attribut] == valeur"""
   for enregistrement in table:
      if ....::
          return ......
   return ......
```

4. Compléter la fonction recherche_attribut_et ci-dessous en respectant sa spécification. Exécuter le test unitaire test_recherche_attributs_et(table_clients).

Proposer une modification de recherche_attribut_et qui prend en paramètres deux tableaux attribut et valeur et recherche un enregistrement pour lequel tous les attributs listés correspondent aux valeurs listées.

3 Requêtes avec opération d'agrégation

3

Exercice 2

On travaille toujours avec la table contenue dans le fichier 'clients.csv' avec le script 'TP_Recherche_Tris_Eleve.py' dans un IDE Python.

1. Compléter la fonction nombre_departement ci-dessous en respectant sa spécification. On donne une postcondition qui doit être vérifiée.

2. Compléter la fonction nombre_departement ci-dessous en respectant sa spécification. Exécuter le test unitaire test_nombre_occurences(table_clients).

3. Compléter la fonction moyenne_visites ci-dessous en respectant sa spécification. On donne une postcondition qui doit être vérifiée.

4. Compléter la fonction minimum_visites ci-dessous en respectant sa spécification. On donne une postcondition qui doit être vérifiée.

```
return min_visites
#postcondition
assert minimum_visites(table_clients) == 2
```

5. ÉCompléter la fonction departement max occurrence ci-dessous en respectant sa spécification. On donne une postcondition qui doit être vérifiée.

```
def departement_max_occurence(table):
   """Paramètre : table sous forme de tableau de dictionnaires
   Valeur renvoyée : tuple formé du nombre d'occurences maximal parmi
        les départements
   et du tableau des départements réalisant ce maximum
    . . . . . . . . . . . .
assert departement_max_occurence(table_clients) == (547, ['59'])
```

Requêtes avec sélection de lignes

Exercice 3

On travaille toujours avec la table contenue dans le fichier 'clients.csv' avec le script $\verb|'TP_Recherche_Tris_Eleve.py| \ dans \ un \ IDE \ Python.$

Un opération de **sélection** consiste à construire une nouvelle table avec les mêmes attributs mais en filtrant les enregistrements (ou lignes) selon une condition logique.

1. Compléter la fonction selection_departement ci-dessous en respectant sa spécification. On donne une postcondition qui doit être vérifiée.

```
def selection_departement(table, departement):
```

```
Paramètres :
      table une table sous forme de tableau de dictionnaires
      department une chaine de caractères représentant un département
   Valeur renvoyée :
      tableau de dictionnaires contenant les enregistrement de table
           dont l'attribut "département" a la valeur passée en paramè
   0.00
   return [enregistrement
          for enregistrement in table if
               # postcondition
assert selection_departement(table_clients, "69")[0]['email'] == '
    nnguyen@noos.fr' \
      and len(selection_departement(table_clients, "69")) == 481
```

2. Compléter la fonction selection_depart_visites_min ci-dessous en respectant sa spécification. On donne une postcondition qui doit être vérifiée.

```
def selection_depart_visites_min(table, departement, visites_min):
   """Paramètres :
      table une table sous forme de tableau de dictionnaires
      department une chaine de caractères représentant un département
      visites min un entier naturel
   Valeur renvoyée :
      tableau de dictionnaires contenant les enregistrement de table
           dont l'attribut "département" a la valeur passée en paramè
           tre et l'attribut visites est >= visites_min"""
   return [enregistrement for enregistrement in table
         assert len(selection_depart_visites_min(table_clients, "69", 100)) == 171
```

Requêtes avec projection sur des colonnes

Exercice 4

On travaille toujours avec la table contenue dans le fichier 'clients.csv' avec le script $\verb|'TP_Recherche_Tris_Eleve.py| \ dans \ un \ IDE \ Python.$

Une opération de **projection** consiste à construire une nouvelle table en filtrant les attributs.

1. Compléter la fonction projection_visites ci-dessous en respectant sa spécification. On donne une postcondition qui doit être vérifiée.

2. Compléter la fonction **projection_visites** ci-dessous en respectant sa spécification. On donne une postcondition qui doit être vérifiée.

3. Compléter la fonction projection_departement_age ci-dessous en respectant sa spécification. On donne une postcondition qui doit être vérifiée.

```
assert projection_departement_age(table_clients, 2021)[:3] == [{'dé
    partement': '79', 'âge': 61}, {'département': '10', 'âge': 27},
    {'département': '73', 'âge': 20}]
```

6 Tri d'une table de données

I V

Méthode

Pour trier une **table de données** implémentée sous forme de **tableau de dictionnaires** en Python, il est préférable d'utiliser les fonctions de tri de la bibliothèque standard plutôt que des tris que nous avons programmés.

D'une part nous avons ainsi la garantie d'une complexité optimale en O(nlog(n)), d'autre part les fonctions de tri de bibliothèque permettent de paramétrer le critère de tri appelé aussi **clef de tri**.

Il existe deux fonctions de tri dans la bibliothèque standard :

- sorted s'applique à un tableau tab avec la syntaxe sorted(tab, key = clef_tri) et renvoie un nouveau tableau avec les éléments du tableau tab triés selon la clef de tri passée en paramètre. Celle-ci est une fonction qui s'applique à un élément du tableau et renvoie une valeur calculée à partir de celle de l'élément. Le tri s'effectue en comparant les valeurs renvoyées par la clef de tri pour chaque élément. Cette valeur peut être un tuple puisque dans une table, un élément est un dictionnaire avec éventuellement plusieurs attributs. Dans ce cas, pour comparer deux valeurs, on applique l'ordre lexicographique: on compare les premières composantes, puis les secondes etc Par défaut la comparaison s'effectue dans l'ordre croissant, mais avec le paramètre optionnel reverse on peut demander un ordre décroissant: sorted(tab, key = clef_tri, reverse = True).
- sort est une fonction de tri en place, elle ne renvoie pas un nouveau tableau. Elle s'applique à un tableau tab avec la syntaxe tab.sort(key = clef_tri), les paramètres sont les mêmes que pour sorted.

Attention, sorted ne renvoie qu'une copie superficielle du tableau! Si ses éléments sont des références et c'est le cas de l'implémentation des tables de données sous forme de tableaux de dictionnaires, il faut effectuer une copie profonde du tableau avec la fonction deepcopy du module copy pour obtenir une vraie copie triée du tableau initiale: sorted(deepcopy(tab), key = clef_tri).

On donne ci-dessous quelques exemples. Notons que pour obtenir un tri décroissant selon l'attribut 'note' puis croissant selon l'attribut 'langage', on ne peut pas utiliser une clef de tri qui renvoie le couple d'attributs ('note', 'langage') car les ordres ne sont pas les mêmes selon les composantes. On procède par composition des tris avec sorted dans l'ordre inverse des priorités de tri : d'abord selon l'attribut note puis selon l'attribut langage.

Une propriété importante des fonctions de tri de bibliothèque sorted et sort est la stabilité du tri : si on enchaîne deux tris successifs (par ordre lexicographique ou composition de sorted), deux éléments égaux pour le second tri conservent l'ordre du premier tri.

```
>>> table = [{'élève' : 'guido', 'langage' : 'python', 'note' : 19}, {'é
    lève' : 'monty', 'langage' : 'python', 'note' : 20}, {'élève' : '
    brian', 'langage' : 'c', 'note' : 20}]
>>> def clef_note(enreg):
      return enreg['note']
>>> def clef_langage(enreg):
       return enreg['langage']
>>> def clef_langage_note(enreg):
       return (enreg['langage'], enreg['note'])
>>> def clef_note_langage(enreg):
       return (enreg['note'], enreg['langage'])
>>> sorted(table, key = clef_note)
[{'élève': 'guido', 'langage': 'python', 'note': 19}, {'élève': 'monty',
      'langage': 'python', 'note': 20}, {'élève': 'brian', 'langage': 'c
     ', 'note': 20}]
>>> sorted(table, key = clef_note, reverse = True)
[{'élève': 'monty', 'langage': 'python', 'note': 20}, {'élève': 'brian',
      'langage': 'c', 'note': 20}, {'élève': 'guido', 'langage': 'python
     ', 'note': 19}]
>>> sorted(table, key = clef_langage_note) #ordre lexicographique (
     langage croissant, note croissant)
[{'élève': 'brian', 'langage': 'c', 'note': 20}, {'élève': 'guido', '
    langage': 'python', 'note': 19}, {'élève': 'monty', 'langage': '
    python', 'note': 20}]
>>> sorted(table, key = clef_note_langage) #ordre lexicographique (note
     croissant, langage croissant)
[{'élève': 'guido', 'langage': 'python', 'note': 19}, {'élève': 'brian',
      'langage': 'c', 'note': 20}, {'élève': 'monty', 'langage': 'python
     ', 'note': 20}]
>>> table_tri_lang_cr = sorted(table, key = clef_langage) #on va
     composer les tris avec sorted
>>> sorted(table_tri_lang_cr, key = clef_note, reverse = True) # é
     quivalent à (note décroissant, langage croissant)
[{'élève': 'brian', 'langage': 'c', 'note': 20}, {'élève': 'monty', '
    langage': 'python', 'note': 20}, {'élève': 'guido', 'langage': '
    python', 'note': 19}]
```

Exercice 5

On travaille toujours avec la table contenue dans le fichier 'clients.csv' avec le script 'TP_Recherche_Tris_Eleve.py' dans un IDE Python.

1. Compléter la clef de tri clef_departement pour que table_tri_departement soit trié dans l'ordre croissant des numéros de département dans le code ci-dessous. Vérifier la postcondition donnée dans le fichier.

```
def clef_departement(enreg):
    return ......

table_tri_departement = sorted(table_clients, key = clef_departement)
```

2. Compléter la clef de tri clef_visites pour que table_tri_visites_decroissant soit trié dans l'ordre décroissant des nombres de visites dans le code ci-dessous. Vérifier la postcondition donnée dans le fichier.

```
def clef_visites(enreg):
    return ......

table_tri_visites_decroissant = sorted(table_clients, key = clef_visites
    , reverse = True)
```

3. Compléter la clef de tri clef_departement_visites pour que table_tri_dep_vis_croissant soit trié dans l'ordre croissant des départements puis des nombres de visites dans le code ci-dessous. Vérifier la postcondition donnée dans le fichier.

```
def clef_departement_visites(enreg):
    return ......

table_tri_dep_vis_croissant = sorted(table_clients, key =
    clef_departement_visites)
```

4. Proposer une instruction qui permette de trier table_clients d'abord par département croissant puis par nombre de visites décroissant. Vérifier la postcondition donnée dans le fichier.

```
table_tri_dep_crois_vis_decrois = ...............
```

5. Le fichier transactions.csv contient une table de données de nouvelles transactions effectuées sur le site marchand. Chaque transaction est identifiée par deux attributs : 'email' pour l'email du client et 'dépenses' pour le montant de la dépense.

```
email,dépenses
wpereira@orange.fr,104.91
ariviere@tiscali.fr,18.37
```

On souhaite mettre à jour les attributs 'visites' et 'dépenses' de table_clients avec les nouvelles transactions. On considère que chaque client est identifié de façon unique par son email et on peut donc insérer efficacement les valeurs de chaque transaction dans table_clients avec une recherche dichotomique sur l'attribut 'email'. Bien sûr, il faut d'abord trier table_clients selon l'attribut 'email'. Compléter le code ci-dessous. Décommenter les postconditions dans le fichier pour vérifier le code et contrôler le contenu du fichier de sortie 'clients_maj.csv'.

```
from copy import deepcopy #pour réaliser une copie de table
def recherche_dicho_croissant(element, table, attribut):
   """Paramètres :
       table un tableau de dictionnaires
       attribut de type str
       element une valeur possible pour l'attribut
   Valeur renovoyée : index de la valeur element de attribut dans table
   debut = 0
   fin = len(table) - 1
   while fin - debut >= 0:
      milieu = (debut + fin) // 2
      if table[milieu][attribut] < element:</pre>
         debut = ......
      elif table[milieu][attribut] > element:
         fin = ......
      else:
         return ......
   return None
def clef_email(enreg):
   return enreg['email']
def maj_depenses_table(table, transactions):
   """Paramètres : table et transactions deux tables sous forme de
       tableaux de dictionnaires
   Valeur renvoyée :
      table_tri un tableau de dictionnaires mise à jour des attributs '
          visites' et 'dépenses'
      de table par les valeurs de transactions"""
   table_tri = sorted(deepcopy(table), key = clef_email)
   table_cible = []
   for enreg in transactions:
      index_email = recherche_dicho_croissant(enreg['email'], table_tri
          , 'email')
      if index_email is not None:
         return table_tri
table_clients = lecture_csv('clients.csv', ',')
transactions = lecture_csv('transactions.csv', ',')
table_tri = maj_depenses_table(table_clients, transactions)
```

```
ecriture_csv(table_tri, 'clients_maj.csv', ',')
```

7 Applications à un autre exemple



Exercice 6

Nous allons utiliser un fichier nommé countries.csv qui contient quelques données sur les différents pays du monde. En voici les premières lignes : les champs sont clairement séparés par des points-virgules.

```
iso;name;area;population;continent;currency_code;currency_name;capital AD;Andorra;468.0;84000;EU;EUR;Euro;6
AE;United Arab Emirates;82880.0;4975593;AS;AED;Dirham;21
AF;Afghanistan;647500.0;29121286;AS;AFN;Afghani;81
```

Les données sont issues du site http://www.geonames.org et ont été légèrement simplifiées. La signification des différents champs est transparente (currency signifie devise), à part le dernier champ, nommé capital et dont les valeurs sont des numéros d'identifiants de villes que l'on trouvera dans un autre fichier nommé cities.csv que nous utiliserons dans le chapitre sur les fusions de tables.

1. On travaille toujours avec le script 'TP_Recherche_Tris_Eleve.py' dans un IDE Python à la suite des exercices précédents. On commence par charger la table avec la fonction lecture_csv, attention le délimiteur de champ n'est pas le symbole , mais ;.

```
table_pays = lecture_csv('countries.csv', ';')
```

2. Compléter la fonction nombre_europe ci-dessous en respectant sa spécification. On donne une postcondition qui doit être vérifiée.

3. Compléter la fonction selection_europe ci-dessous en respectant sa spécification. On donne une postcondition qui doit être vérifiée.

4. Compléter la fonction selection_europe_non_euro ci-dessous en respectant sa spécification. On donne une postcondition qui doit être vérifiée.

5. Compléter la fonction projection_aire ci-dessous en respectant sa spécification. On donne une postcondition qui doit être vérifiée.

6. Compléter la fonction projection_pays_densite ci-dessous en respectant sa spécification. On donne une postcondition qui doit être vérifiée.

```
assert projection_pays_densite(table_pays)[:3] == [{'pays': 'Andorra', 'densité': 179.48717948717947},
{'pays': 'United Arab Emirates', 'densité': 60.033699324324324},
{'pays': 'Afghanistan', 'densité': 44.974959073359074}]
```

7. Écrire une fonction maximum_densite respectant la spécification ci-dessous. On donne une postcondition qui doit être vérifiée.

```
def maximum_densite(table):
    """Paramètre : table de countries.csv
    Valeur renvoyée : tuple avec le nom du pays de densité maximale de
        population et cette densité maximale"""

assert maximum_densite(table_pays) == ('Monaco', 16905.128205128207)
```

8. Écrire une fonction population_par_continent respectant la spécification ci-dessous. On donne une postcondition qui doit être vérifiée.

```
'AS': 4119426856, 'NA': 539886359, 'AF': 1018849428, 'SA': 400143568, 'DC': 36066083}
```

9. Écrire une fonction densite_max_top5 respectant la spécification ci-dessous. On donne une postcondition qui doit être vérifiée.

```
def densite_max_top5(table):
    """Paramètre : table de countries.csv
Valeur renvoyée : table avec les noms et les densités des 5 pays les
    plus densément peuplées dans l'ordre décroissant des densités de
    population"""

assert densite_max_top5(table_pays) == [{'pays': 'Monaco', 'densité':
    16905.128205128207},
{'pays': 'Singapore', 'densité': 6786.5872672152445},
{'pays': 'Hong Kong', 'densité': 6317.478021978022},
{'pays': 'Gibraltar', 'densité': 4289.846153846154},
{'pays': 'Vatican', 'densité': 2093.18181818181818}]
```

8 Synthèse

🖍 Synthèse

Lorsqu'une table de données contenue dans un fichier CSV est chargée dans une structure de données Python comme un tableau de dictionnaires, on peut la manipuler avec des requêtes de recherche, d'agrégation, de sélection sur les lignes ou de projection sur les colonnes. Il est possible également de trier les enregistrements d'une table avec la fonction de bibliothèque sorted en lui passant une fonction clef de tri. Elle garantit la stabilité du tri : les éléments égaux conservent leur ordre intial. On peut ainsi extraire des informations d'une table ou construire de nouvelles tables. En classe de terminale, nous étudierons les bases de données dans le modèle relationnel, qui peuvent être modélisées par des tables. Les requêtes pour les interroger seront similaires mais exprimées dans un langage spécifique, le SQL.